Projeto 2

Métodos Estatísticos para Inteligência Artificial

Grupo 5:

[redacted] – [redacted]

[redacted] – [redacted]

[redacted] – [redacted]

[redacted] – [redacted]

Vasco Caetano – [redacted]

1. Introdução

A Inteligência Artificial moderna provém do resultado de princípios estatísticos aplicados; é através desta estatística que podemos recolher informações fulcrais e transformar dados brutos em conhecimento. Este relatório foca-se na análise do conjunto de dados Soils, especificamente num subconjunto de nove variáveis: **pH, N, Dens, P, Ca, Mg, K, Na e Conduc**. A análise divide-se numa fase inicial de exploração e numa fase de modelação preditiva através de regressão linear.

2. Objetivos de Estudo

O projeto visa atingir os seguintes objetivos fundamentais:

1. **Análise Exploratória de Dados:** Aplicar métodos estatísticos univariados e multivariados para compreender a estrutura e variabilidade das propriedades do solo.
2. **Modelação de Regressão:** Explicar a variável dependente (**pH**) utilizando as restantes variáveis como previsores.
3. **Otimização do Modelo:** Identificar o melhor subconjunto de regressores baseando-se no *Parsimony Principle*.
4. **Inferência e Previsão:** Calcular e comparar intervalos de confiança e de previsão para observações específicas (12 e 24), discutindo a incerteza associada.

3. Análise Exploratório e Detecção de Anomalias

3.1. Análise de Tendência Central e Dispersão

Ao analisar inicialmente as estatísticas descritivas das variáveis do *dataset* "*Soils*", notou-se uma disparidade nas medidas de localização clássicas e robustas, sugerindo a influência de valores extremos e assimetria na distribuição dos dados. Verifica-se que a média *winsorizada* tem uma estimativa mais estável do centro dos dados visto que reduz o impacto de pontos atípicos. A seguinte tabela ilustra a divergência entre estas medidas, com destaque para a variável ***P***.

Filter

	pH	N	Dens	P	Ca	Mg	K	Na	Conduc
Media_Classica	4.669	0.102	1.316	166.167	8.029	8.465	0.466	5.600	6.589
Media_Winsor	4.607	0.093	1.337	156.854	7.835	8.526	0.462	5.602	6.516
Mediana	4.545	0.084	1.400	131.000	7.305	8.515	0.425	5.520	6.635

Fig. 1 Resultados média, média winsorizada e mediana para variáveis em estudo.

O ***P*** (Fósforo) tem uma média clássica substancialmente superior que a mediana e a média *winsorizada.* Este facto, indica uma distribuição bastante assimétrica à direita, onde um pequeno conjunto de observação com valores muito elevados inflaciona a média. O ***N*** (Azoto) também apresenta um comportamento semelhante, mas não tem um desvio tão acentuado em relação ao ***P***.

Relativamente à dispersão, o Desvio Padrão **(*SD*),** por ser sensível a *outliers*, tende a ser superior ao Desvio Absoluto da Mediana **(*MAD*)**. Mais uma vez, esta diferença é evidente na variável ***P***. A figura abaixo demonstra uma comparação entre o Desvio Padrão e Desvio Absoluto da Mediana.

Filter

	pH	N	Dens	P	Ca	Mg	K	Na	Conduc
SD	0.672	0.067	0.220	81.161	3.256	1.368	0.224	3.289	3.987
MAD	0.852	0.053	0.208	47.443	3.469	1.549	0.282	4.337	5.159

Fig. 2 Resultados desvio padrão e desvio absoluto mediano para variáveis em estudo.

O ***SD*** de 81.16 é quase o dobro do ***MAD*** de 47.44. Isto confirma a inflação da variabilidade clássica devido à existência de valores extremos.

Filter

	pH	N	Dens	P	Ca	Mg	K	Na	Conduc
pH	0.45138896	0.028726343	-0.08696649	32.227766	1.7688953	-0.3638162	0.08720186	-1.5319130	-2.0489222
N	0.02872634	0.004510273	-0.01275367	4.590521	0.1859121	-0.0479229	0.01016699	-0.1793430	-0.2152471
Dens	-0.08696649	-0.012753670	0.04829291	-14.155461	-0.5662856	0.1473642	-0.03282872	0.5365174	0.6682129
P	32.22776596	4.590521277	-14.15546099	6587.035461	181.6979787	-54.2975887	10.10063830	-206.3031206	-246.5027305
Ca	1.76889535	0.185912088	-0.56628564	181.697979	10.6011847	-1.9044056	0.52565505	-8.4482215	-10.8030520
Mg	-0.36381622	-0.047922899	0.14736418	-54.297589	-1.9044056	1.8719785	-0.10929947	2.5404105	2.7729026
K	0.08720186	0.010166995	-0.03282872	10.100638	0.5256551	-0.1092995	0.05015160	-0.5105846	-0.6725013
Na	-1.53191303	-0.179343005	0.53651738	-206.303121	-8.4482215	2.5404105	-0.51058457	10.8174083	12.7528334
Conduc	-2.04892221	-0.215247114	0.66821294	-246.502730	-10.8030520	2.7729026	-0.67250133	12.7528334	15.8998297

Fig. 3 Resultados da matriz de covariância S.

Ao analisar a matriz de covariância S, observa -se que a Variância Total é dominada pela variável ***P***. As variáveis como ***N*** ou ***K*** têm variâncias insignificantes nesta escala. Esta disparidade de

escalas impossibilita a aplicação direta de métodos baseados em distâncias ou covariâncias sem uma prévia padronização dos dados.

Filter

	V1
Var_Generalizada	0.00
Var_Total	6626.78

Fig. 4 Variância multivariada para as variáveis em estudo.

3.2 Deteção e Caracterização de Outliers

Para uma deteção formal de anomalias multivariadas, foram utilizadas as **Distâncias de *Mahalanobis* Robustas** (estimador MCD), que generalizam o conceito de *Z-score* tendo em conta a estrutura de correlação dos dados.

A análise do gráfico "*QQ-Plot*: Distâncias de *Mahalanobis* (Robustas)" permite identificar observações que se desviam severamente da distribuição Qui-Quadrado esperada ($\chi^2_{0.975}$).

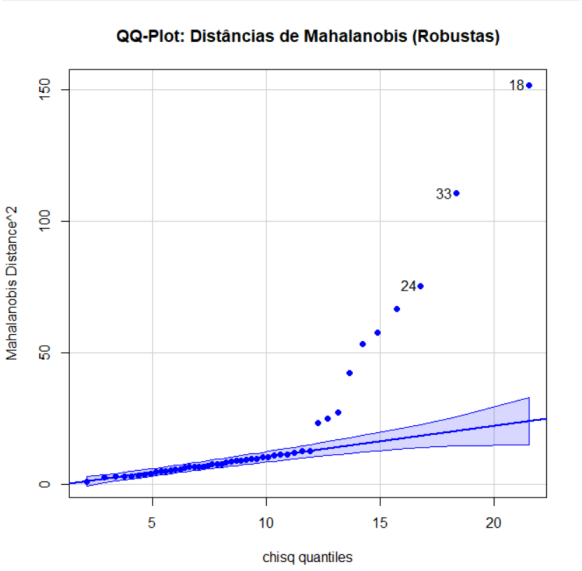


Fig. 4 QQ-Plot: Distâncias de Mahalanobis (Robustas).

- As observações identificadas com os índices **18, 24 e 33** destacam-se como *outliers* multivariados severos, situando-se muito acima da linha de referência e do *cut-off* teórico

Esta conclusão multivariada é corroborada pela análise univariada visual:

• **Boxplots:** A observação **33** aparece explicitamente como um *outlier* superior na variável ***P*** (valores acima de 400, quando a mediana é 131).

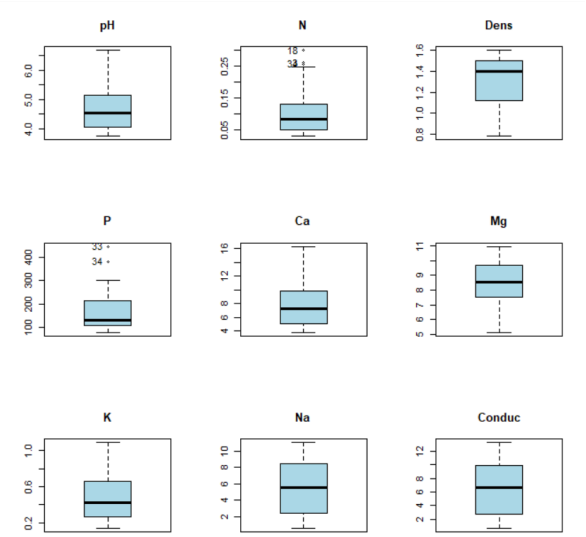


Fig. 5 Boxplots univariados.

• **QQ-Plots Univariados:** Nos gráficos de normalidade, é visível que as caudas das distribuições fogem às bandas de confiança. Por exemplo, a variável ***Conduc*** e ***Na*** mostram desvios sistemáticos nas extremidades.

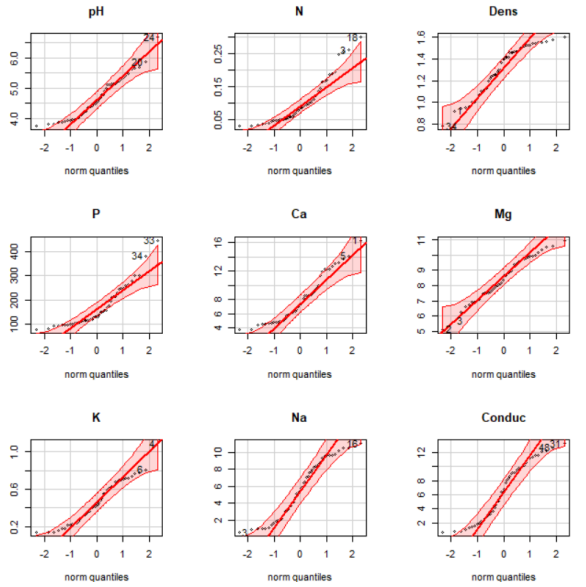


Fig. 6 Gráficos QQ (Quantile-Quantile) univariados.

Adicionalmente, a matriz de correlação revela uma colinearidade quase perfeita entre ***Na*** e ***Conduc*** (r=0.97). Isto sugere redundância na informação: a condutividade elétrica do solo nestas amostras é quase inteiramente explicada pela concentração de Sódio, o que poderá implicar a necessidade de remover uma destas variáveis em análises de regressão futuras para evitar multicolinearidade.

Em suma, a presença de *outliers* multivariados (obs. 18, 33, 24) e a forte assimetria de variáveis como o Fósforo (***P***) requerem o uso de métodos robustos e a padronização das variáveis para as etapas seguintes do projeto.

4. Análise de Regressão Linear Múltipla

4.1. Aplicação do Modelo de Regressão Linear ao *dataset*

Para investigar a relação entre o *pH* do solo e os elementos químicos em análise, procedeu-se inicialmente ao ajustamento de um modelo de regressão linear múltipla completo, considerando todas as 8 variáveis preditivas disponíveis. A avaliação da qualidade do modelo baseou-se nos seguintes critérios:

1. Teste de Significância Global (*F-test*) - Avalia se existe, globalmente, uma relação linear entre a resposta e o conjunto de regressores (H_0: $\beta_1 = \cdots = \beta_{\square} = 0$).
2. Coeficiente de Determinação (R^2) - Para quantificar a proporção da variabilidade do *pH* explicada pelo modelo.
3. Testes *t* individuais - Aferem a significância estatística de cada coeficiente de regressão isoladamente (H_0: $\beta_{\square} = 0$).

Ora a partir do seguinte output:

```
Call:
lm(formula = pH ~ ., data = dados_soils)

Residuals:
     Min       1Q   Median       3Q      Max
-0.54083 -0.22400 -0.06742  0.21067  1.13795

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.494501   1.063223   3.287 0.002150 **
N           -2.253772   2.324808  -0.969 0.338298
Dens         0.718301   0.525992   1.366 0.179886
P            0.001638   0.001366   1.199 0.237827
Ca           0.156587   0.039002   4.015 0.000262 ***
Mg          -0.060945   0.049129  -1.241 0.222199
K           -0.403777   0.393937  -1.025 0.311688
Na           0.181815   0.082528   2.203 0.033564 *
Conduc      -0.210055   0.073907  -2.842 0.007093 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.3641 on 39 degrees of freedom
Multiple R-squared:  0.7563,    Adjusted R-squared:  0.7063
F-statistic: 15.13 on 8 and 39 DF,  p-value: 8.288e-10
```

Fig. 7 Sumário do modelo inicial com todas as variáveis preditivas.

Podemos concluir que observando a última linha do output (*F-statistic*: 15.13), o *p-value* associado é 8.288e-10. Como o *p-value* é muito inferior ao nível de significância habitual ($\alpha = 0{,}05$), rejeitamos a hipótese nula (H_0: $\beta_1 = \beta_2 = \ldots = \beta_{\square} = 0$). Existe evidência estatística forte de que o

modelo de regressão é significativo, ou seja, pelo menos uma das variáveis preditivas ajuda a explicar o *pH* do solo.

Quanto à comparação com o Coeficiente de Determinação (R^2), o valor de *Multiple R-squared* é 0,7563. Isto significa que aproximadamente 75,6% da variabilidade do *pH* é explicada por este conjunto de variáveis. O facto de este valor ser bastante elevado, é coerente com o resultado do teste F e demonstra que ambos indicam que o modelo linear se ajusta bem aos dados.

Relativamente à exclusão de variáveis, observando a coluna Pr(>|t|), vemos que muitas variáveis têm valores superiores a 0.05:

- N ($p \approx 0.338$)
- K ($p \approx 0.312$)
- P ($p \approx 0.238$)
- Mg ($p \approx 0.222$)
- Dens ($p \approx 0.180$)

Assim, existe evidência clara de que um subconjunto de variáveis deve ser excluído. A presença de tantas variáveis não significativas sugere que o modelo está com informação redundante, e por isso deve ser simplificado.

Com o objetivo de identificar o subconjunto de regressores com maior relevância estatística, procedeu-se à redução do modelo (*Feature Selection*) recorrendo ao método de Backward Elimination.

Esta escolha metodológica fundamentou-se na estrutura do problema proposto, que sugere a validação inicial de um modelo completo seguida da exclusão de variáveis não informativas, bem como na robustez do algoritmo perante a natureza dos dados. A opção pelo *Backward Elimination* justifica-se, principalmente pela sua capacidade de avaliar a contribuição de cada variável na presença simultânea de todas as outras, esta característica permite superar as limitações de abordagens como o *Forward Selection* que, ao introduzir variáveis isoladamente, pode falhar na identificação de regressores que apenas revelam significância estatística em conjunto (um aspeto crucial num contexto de provável multicolinearidade entre dados do solo).

Adicionalmente, esta abordagem impõe um critério de seleção baseado no *p-value* (α=0.05) que é mais rigoroso do que a simples maximização do R^2 ajustado, garantindo assim o cumprimento do *Parsimony Principle* e resultando num modelo final mais robusto e interpretável.

O algoritmo *Backwards Elimination* declara que como fase inicial: dá-se ajuste do modelo com as variáveis disponíveis, procedendo-se à identificação da variável com o maior *p-value*, superior ao nível de significância fixado ($\alpha = 0.05$) e removendo-a. Este processo é repetido de forma incremental e sequencial até restarem apenas as variáveis que podem ser consideradas estatisticamente significantes. Para o caso em mãos no fim da execução deste processo restam 3 variáveis fortemente preditivas do valor do *pH*: *Ca*, *Conduc* e *Na*.

A remoção sequencial das variáveis não significativas, reajustando o modelo a cada passo, deu-se pela seguinte ordem de exclusão:

- N ($p \approx 0.34$)
- P ($p \approx 0.40$)
- Mg ($p \approx 0.23$)
- K ($p \approx 0.21$)
- Dens ($p \approx 0.12$)

O processo foi interrompido quando todas as variáveis remanescentes no modelo apresentaram significância estatística ao nível de 5%. Conforme pode ser verificado no seguinte output:

```
> # Passo 6: Remover Dens (maior p-value: 0.118)
> modelo_6 <- update(modelo_5, . ~ . - Dens)
> print("--- SUMMARY DO MODELO 6 (sem Dens) ---")
[1] "--- SUMMARY DO MODELO 6 (sem Dens) ---"
> summary(modelo_6)

Call:
lm(formula = pH ~ Ca + Na + Conduc, data = dados_soils)

Residuals:
     Min       1Q   Median       3Q      Max
-0.56973 -0.22509 -0.01842  0.20632  1.37222

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.15117    0.39369  10.544 1.27e-13 ***
Ca           0.10553    0.03057   3.452  0.00124 **
Na           0.15052    0.07195   2.092  0.04224 *
Conduc      -0.17789    0.06575  -2.705  0.00967 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.3738 on 44 degrees of freedom
Multiple R-squared:  0.7102,    Adjusted R-squared:  0.6904
F-statistic: 35.94 on 3 and 44 DF,  p-value: 6.711e-12
```

Fig. 8 Sumário do modelo final com somente as variáveis estatisticamente significativas.

Podemos concluir portanto que sobraram 3 variáveis:

Olhando para a coluna Pr(>|t|):

- Ca: 0,00124 (< 0.05)
- Conduc: 0,00967 (< 0.05)
- Na: 0,04224 (< 0.05)

Todas as variáveis restantes (*Ca*, *Na*, *Conduc*) têm agora um *p-value* inferior a 0.05. Isto significa que todas são estatisticamente significativas. Assim, o modelo 6 é o modelo final e apresenta um R^2 de 0.7102.

Por fim, conforme podemos registar pela coluna “Estimate”:

$$pH = 4.151 + 0.106 \times Ca + 0.151 \times Na - 0.178 \times Conduc$$

4.2. Estimativa Pontual e Intervalar: Comparação de IC vs. IP para as Observações 12 e 24

Recorrendo ao modelo final selecionado ($pH = 4.151 + 0.106 \times Ca + 0.151 \times Na - 0.178 \times Conduc$), procedeu-se ao cálculo das estimativas pontuais e intervalares para as observações 12 e 24. Foram determinados os Intervalos de Confiança (IC) para a resposta média e os Intervalos de Previsão (IP) para uma nova observação individual, fixando-se um nível de confiança de 97,5%.

Os resultados obtidos encontram-se sumarizados na Tabela 1.

Filter

	Valor Ajustado (ŷ)	Intervalo de Confiança (97,5%)	Intervalo de Previsão (97,5%)
12	4,460	[4,280 ; 4,640]	[3,574 ; 5,346]
24	5,298	[4,839 ; 5,757]	[4,316 ; 6,279]

Fig. 8 Tabela de estimativas pontuais, intervalos de confiança e intervalos de previsão a 97.5% das observações 12 e 24.

4.3. Interpretação dos Valores Previstos

Analisando as características físico-químicas das observações, constata-se que a Observação 24 apresenta uma concentração de Cálcio (12.68) significativamente superior à da Observação 12 (6.61). Dado que a variável Ca possui um coeficiente positivo no modelo final (β^Ca≈+0.106), este aumento na concentração de cálcio contribui decisivamente para que o valor previsto do pH na observação 24 (ŷ=5.30) seja superior ao da observação 12 (ŷ=4.46). Este comportamento é coerente com a química do solo, onde a presença de cálcio está geralmente associada a uma menor acidez (pH mais elevado).

4.4. Discussão e Comparação dos Resultados

A análise dos valores tabelados evidencia que, para ambas as observações e mantendo o mesmo nível de confiança, a amplitude dos Intervalos de Previsão (IP) é substancialmente superior à dos Intervalos de Confiança (IC). Esta diferença de amplitude é esperada e fundamenta-se na distinção teórica entre os dois tipos de inferência:

1. O Intervalo de Confiança visa estimar o valor esperado (médio) da variável resposta para um dado conjunto de regressores $E\ [Y|x_0]$. A incerteza associada restringe-se apenas à variância dos estimadores dos coeficientes da regressão.
2. O Intervalo de Previsão visa antecipar o valor de uma única nova observação futura Y_{new}. Neste caso, à incerteza da estimação da média soma-se a variabilidade intrínseca e irredutível do erro aleatório ε associada a cada medição individual.

Matematicamente, enquanto a variância para o IC é dada por $\boldsymbol{\sigma}^2[x_0^T(X^T X)^{-1} x]_0$ a variância do erro de previsão inclui um termo adicional unitário, resultando em $\boldsymbol{\sigma}^2[1+x^T_0.(X^T X)^{-1}x_0]$

Consequentemente, a previsão de um valor pontual acarreta sempre maior incerteza do que a estimativa de uma média populacional, resultando em intervalos mais largos.

4.5. Validação com os valores reais

Ao comparar-se os intervalos com os valores reais de pH observados nos dados originais, verificam-se dois cenários distintos:

1. Relativamente à Observação 12, o valor real (3.89) está fora do Intervalo de Confiança (que começa em 4.28), mas está contido dentro do Intervalo de Previsão (3,57<3,89<5,35). Isto é o comportamento esperado para um modelo bem ajustado: a média pode ser diferente do valor individual, mas o intervalo de previsão é suficientemente largo para capturar a variabilidade individual.
2. Relativamente à Observação 24, o valor real (6.67) encontra-se fora de ambos os intervalos, inclusive do Intervalo de Previsão (cujo limite superior é 6.28). Isto sugere que, para esta observação específica, o modelo subestimou significativamente o valor do pH (resíduo elevado), indicando que este ponto pode ser um outlier ou que existem fatores não explicados pelas variáveis selecionadas (Ca, Na, Conduc) que influenciaram este valor atípico.

5. Conclusão

A Análise Exploratória de Dados evidenciou as limitações das métricas tradicionais, como a média e o desvio padrão, especialmente em variáveis com forte assimetria e valores extremos (caso do Fósforo). Para contornar este problema, a aplicação de estimadores robustos (Média Winsorizada e MAD) e das distâncias de Mahalanobis revelou-se fundamental. Esta abordagem permitiu não só uma caracterização mais fiel dos dados, como também a detecção eficaz de *outliers* multivariados que poderiam comprometer a qualidade da análise final.

O presente estudo permitiu aplicar metodologias de análise estatística multivariada para modelar as propriedades físico-químicas do conjunto de dados *Soils*, com o objetivo de explicar a variabilidade do pH através de variáveis preditoras químicas e físicas.

A análise de regressão linear múltipla revelou-se eficaz na identificação dos determinantes do pH. Partindo de um modelo inicial complexo com oito regressores, a aplicação do método de seleção de variáveis *Backward Elimination* permitiu simplificar a estrutura do modelo sem sacrificar significativamente a sua capacidade explicativa, em concordância com o *Parsimony Principle*. O processo iterativo de remoção de variáveis não significativas (N, P, Mg, K, Dens) resultou num modelo final reduzido composto por apenas três preditores: Cálcio (Ca), Sódio (Na) e Condutividade (Conduc).

Este modelo final apresenta um coeficiente de determinação (R^2) de 0.7102, indicando que aproximadamente 71% da variabilidade do pH é explicada por estas três variáveis. A validade do modelo foi corroborada pelo teste F global e pelos coeficientes remanescentes ao nível de 5%.

Relativamente à comparação entre os Intervalos de Confiança e os Intervalos de Previsão para as observações 12 e 24 confirmaram-se as expectativas teóricas. Verificou-se que os intervalos de

previsão são mais amplos, o que reflete posteriormente a incerteza adicional associada à variabilidade intrínseca do erro aleatório numa nova observação individual. Adicionalmente, a análise destas observações permitiu detetar potenciais limitações do modelo em pontos específicos (como observado na discrepância da observação 24, o que sugere a importância de uma análise contínua de resíduos e *outliers* para garantir a robustez das previsões em cenários reais.

Em suma, conclui-se que o pH do solo neste conjunto de dados é maioritariamente influenciado pelos níveis de Cálcio, Sódio e Condutividade, constituindo estas variáveis o subconjunto ideal para futuras previsões e caracterizações relativas ao solo.

6. Bibliografia

Rodrigues, I. M. [redacted]. MEIA - Chapter 1: Exploratory Data Analysis [Slides de aula]. Departamento de Matemática, Instituto Superior Técnico .

Rodrigues, I. [redacted]. *MEIA - Chapter 1: Exploratory Data Analysis: Iris dataset solutions* [PowerPoint/PDF]. Plataforma de Apoio ao Ensino, Instituição de Ensino Superior.

Rodrigues, I. M. [redacted]. MEIA - Chapter 2: Dimensionality reduction: principal component analysis [Slides de aula]. Departamento de Matemática, Instituto Superior Técnico .

Rodrigues, I. M. [redacted]. Principal Components Analysis [Apontamentos manuscritos]. Departamento de Matemática, Instituto Superior Técnico.

Rodrigues, I. M. (2023). Food Price Data PCA in R (PCA-in-R_Ex-8) [Guião de Laboratório R]. Departamento de Matemática, Instituto Superior Técnico .

Rodrigues, I. M. [redacted]. MEIA - Chapter 3:Regression Analysis [Slides de aula]. Departamento de Matemática, Instituto Superior Técnico.